

Procena Obrtnog Momenta Asinhronne Mašine

Jovana Lazić

Novi Sad, 2026.

1 1. Opis problema

Cilj ovog projekta je razvoj i evaluacija modela mašinskog učenja za indirektnu procenu obrtnog momenta (M) asinhronne mašine na osnovu merenih električnih (struje, naponi, faktori popune) i pogonskih parametara (brzina obrtanja ω).

U realnim elektromotornim pogonima, direktno merenje obrtnog momenta pomoću fizičkih senzora (tenzometarskih traka ili rotacionih torzionih dinamometara) često je neizvodljivo, preskupo ili smanjuje pouzdanost mehaničkog sklopa. Sa druge strane, konvencionalni analitički fizički modeli pate od nelinearnosti, promene otpornosti namotaja sa temperaturom i zasićenja magnetskog kola. Primena algoritama mašinskog učenja omogućava visoko preciznu procenu momenta u realnom vremenu uz korišćenje isključivo standardno pristupačnih merenih veličina.

2 2. Struktura projekta i Pipeline

Projekat je organizovan modularno, gde svaka skripta obezbeđuje jasnu separaciju odgovornosti tokom obrade podataka, eksperimentisanja i evaluacije.

2.1 Organizacija skripti

- `data_loader_cleaner.py` – Učitavanje sirovih vremenskih serija, provera kvaliteta, uklanjanje nestacionarnih tranzijenata i provera IQR outlier-a.
- `feature_engineering.py` – Agregacija trofaznih veličina u prosek, izračunavanje izvedenih fizikalnih veličina (npr. P_{in}/ω) i uklanjanje varijabli sa curenjem cilja.
- `eda_analysis.py` – Eksplorativna analiza, računanje korelacionih matrica, VIF faktora multikolinearnosti i korelacija sa momentom.
- `train_eval.py` – Podela mernih serija (`GroupKFold`), unakrsna validacija, treniranje regresionih modela i evaluacija na test skupu.
- `feature_selection.py` – Rangiranje atributa po permutacionom značaju i selekcija minimalnog podskupa (k) primenom pravila 1-STD.

- `hyperparameter_tuning.py` – Optimizacija hiperparametara za odabrane nelinearne ansambl modele.

2.2 Arhitektura Pipeline-a

Celi tok obrade i evaluacije prikazan je na Slici 1.




Figure 1: Dijagram toka pipeline-a obrade podataka i obuke modela.

3. Skup podataka

Eksperimenti su sprovedeni na skupu podataka mernih serija asinhronne mašine.

- **Inicijalni obim:** 94,241 vremenskih prozora raspoređenih u 276 mernih serija (`series_id`).
- **Provera kvaliteta:** Nije uočena nijedna nedostajuća vrednost ($\text{NaN} = 0$), niti duplirani zapisi u sirovom obliku.
- **Potpunost prozora:** Svi vremenski prozori sadržali su više od 90% uzoraka poduzorkovanja.

- **Filtriranje tranzijenata:** Uklonjeno je 943 prozora (gornjih 1% po raspodeli) sa izrazito visokom standardnom devijacijom momenta (`torque_std > 0.0415`).
- **Konačni skup:** 93,298 prozora unutar 276 mernih serija.

4. Priprema podataka i sprečavanje curenja

- **Filtriranje nestacionarnih stanja:** Brisanje ekstremnih dinamika (`torque_std > 0.0415`) sprovedeno je da bi se usmerilo učenje na ustaljena radna stanja.
- **IQR Outlieri:** Analiza po formuli $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ primenjena je na varijable `torque`, `i_a_rms`, `i_b_rms` i `i_c_rms`. Identifikovano je 0% nevažjećih tačaka, što potvrđuje da su sve vrednosti u skupu fizički ostvarive radne tačke motora.
- **Sprečavanje curenja informacija (Target Leakage & Data Leakage):**
 - Varijabla `p_mech` je eksplicitno izbačena jer predstavlja direktan proizvod $P_{mech} \approx M \cdot \omega$.
 - Podela podataka na trening (220 serija) i test (56 serija) izvršena je striktno na nivou mernih serija (`GroupKFold`). Time se onemogućava da se prozori iz iste merne serije nađu i u treningu i u testu.

Trofazni sistemi se odlikuju visokom simetrijom i međusobnom korelacijom ($r \approx 1.0$). Zbog toga su pojedinačne faze struja (`i_a/b/c`), napona (`u_1/2/3`) i faktora popune (`d_a/b/c`) spojene u prosečne (RMS) vrednosti (`i_rms`, `u_rms`, `d_std`). Generisan je i fizikalno izveden atribut `p_in_mot_over_omega` (P_{in}/ω).

Atributi koji nisu ulaz u model: `series_id` (ključ za podelu), `window/t` (vreme), `p_mech` (leakage), `n_samples_hf` i `torque_std`.

5. 6. Eksplorativna analiza podataka (EDA)

5.1 Multikolinearnost

Identifikovana su 2 para atributa sa izuzetno visokom korelacijom ($|r| > 0.95$):

- `d_std` i `u_rms`: $r = 0.969881$
- `theta_s_mean` i `theta_r_mean`: $r = 0.950722$

Faktor uvećanja varijanse (VIF) dodatno potkrepljuje prisustvo jake multikolinearnosti (Tabela 1).

5.2 Korelacija sa cilnom promenljivom (`torque`)

Top 5 atributa po apsolutnoj korelativnoj povezanosti sa obrtnim momentom:

1. `p_in_mot`: $r = 0.792581$
2. `p_in_inv`: $r = 0.733089$
3. `u_dc`: $r = -0.610659$

Table 1: Faktor uvećanja varijanse (VIF) za ulazne atribute.

Atribut	VIF	Atribut	VIF
d_std	39.91	p_in_inv	13.29
u_rms	34.47	p_in_mot	10.85
theta_s_mean	18.66	i_rms	3.93
theta_r_mean	15.04	u_dc	2.67

4. p_in_mot_over_omega: $r = 0.409055$

5. d_std: $r = 0.206231$

6 7. Odabir i treniranje modela

Eksperiment merged_power_over_omega obuhvata 10 ulaznih atributa na 220 mernih serija za trening i 56 za test. Evaluacija svih modela prikazana je u Tabeli 2.

Table 2: Usporedni pregled performansi modela na cross-validation (CV) i test skupu.

Model	CV R^2 Mean	CV R^2 Std	CV RMSE	Vreme (s)	Test R^2	T
Baseline (Mean)	-0.0316	0.0430	4.3448	0.1	–	
LinearRegression	0.6848	0.0860	2.3643	0.1	0.6853	
Ridge	0.6848	0.0860	2.3643	0.1	–	
KNN	0.1983	0.6592	3.5145	2.1	–	
RandomForest	0.5718	0.1935	2.6880	164.0	–	
HistGradientBoosting	0.6905	0.1112	2.3146	2.9	–	
Physics (P/ω nekalibrisan)	-5.0965	–	10.6843	–	-1.6086	
Physics (Kalibrisan LR na P/ω)	0.1066	0.1173	–	–	0.1438	

Kao što se vidi na Slici 2, linijski i gradient boosting modeli pokazuju dominantne performanse nad baznim fizičkim formulama.

7 8. Analiza rezultata i izbor finalnog modela

Iako HistGradientBoosting ostvaruje za nijansu viši prosečni CV R^2 (0.6905), modeli LinearRegression i Ridge (0.6848) spadaju u opseg od 1-STD razlike. S obzirom na drastično manju složenost i vreme obuke (0.1 s naspram 2.9 s), **LinearRegression** je izabran kao finalni model.

Metrike finalnog modela na nezavisnom test skupu:

- $R^2 = 0.6853$
- RMSE = 2.5139 Nm (što čini 13.19% opsega momenta u test skupu od 19.05 Nm)
- MAE = 1.7842 Nm




Figure 2: Grafik poređenja R^2 skora analiziranih modela.

8 9. Odabir najznačajnijih atributa

Značaj atributa izračunat je preko *Permutation Importance* metode na CV validacionim foldovima (Tabela 3).

Table 3: Permutacioni značaj ulaznih atributa.

Rang	Atribut	Značaj	Rang	Atribut	Značaj
1	d_std	3.0930	6	theta_r_mean	0.1494
2	u_rms	2.5951	7	i_rms	0.1330
3	p_in_inv	0.4424	8	speed_rpm	0.0478
4	p_in_mot	0.3709	9	p_in_mot_over_omega	0.0317
5	theta_s_mean	0.1683	10	u_dc	0.0133

Redukcija atributa primenom pravila 1 standardne greške (1-STD):

- $k = 3$: CV $R^2 = 0.5175$, Test $R^2 = 0.4823$ (d_std, u_rms, p_in_inv)
- $k = 5$: CV $R^2 = \mathbf{0.6427}$, Test $R^2 = \mathbf{0.6029}$ (d_std, u_rms, p_in_inv, p_in_mot, theta_s_mean)
- $k = 8$: CV $R^2 = 0.6652$, Test $R^2 = 0.6544$
- Svi ($k = 10$): CV $R^2 = 0.6848$, Test $R^2 = 0.6853$

Najmanji podskup atributa čiji je CV R^2 unutar 1-STD od punog skupa iznosi $k = 5$.

9 10. Leave-Series-Out evaluacija i serijalizacija

Evaluacija finalnog linijskog modela sprovedena na celokupnom skupu od 276 serija sistemom *Leave-Series-Out*:

- $R^2 = 0.7056$

- RMSE = 2.3701 Nm
- MAE = 1.6555 Nm
- Disperzija RMSE po serijama: Min = 0.0511 Nm, Medijana = 1.1206 Nm, Max = 11.6670 Nm.

Model je serijalizovan na lokaciju:

`...\models\merged_power_over_omega\final_torque_model.joblib`

10 11. Zaključak

U okviru projekta uspešno je razvijen pipeline za procenu obrtnog momenta asinhronne mašine. Rezultati potvrđuju da regresioni modeli mašinskog učenja ($R^2 \approx 0.685\text{--}0.705$) drastično nadmašuju konvencionalne analitičke fizičke proračune ($R^2 \approx 0.106\text{--}0.143$). Izabrani `LinearRegression` model nudi idealan kompromis između preciznosti i brzine izvršavanja u realnom vremenu.